DIRECCIÓN GENERAL DE ESCUELAS — PROVINCIA DE MENDOZA

Instituto Superior Manuel Belgrano (ISMB)

Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial

WineLytics V2

Documentación de Software Analista de Datos — Examen Parcial Nro 2

- **Unidad / Espacio Curricular:** Programación Orientada al Análisis de Datos
- **Docente:** Prof. Juan Caballero Gallar
- **Curso y Sede:** 2do 4ta — Sede Godoy Cruz
- **Ciclo Lectivo:** 2026
- **Estudiantes:** Franco Ciccarelli
- **Fecha de Presentación:** 30/10/2026
- **Repositorio GitHub:** https://github.com/DarkosCode/WineLytics-V2

b. Proyecto

i. Resumen ejecutivo (problema de negocio y público objetivo)

Problema de negocio: Las bodegas vitivinícolas mendocinas enfrentan dos desafíos críticos: (1) el equilibrio entre el stock inmovilizado en depósito y el riesgo de quiebre en líneas de crianza (*Reserva* y *Gran Reserva*), cuyos tiempos de reposición son prolongados; y (2) la fuerte estacionalidad cruzada por varietal (el vino blanco *Torrontés* multiplica su demanda en verano, mientras que los tintos *Malbec* y *Cabernet Sauvignon* concentran sus picos en invierno), combinada con la sensibilidad al precio según canal (*Mercado Interno* vs. *Exportación*).

Solución propuesta: WineLytics V2 integra un pipeline ETL en `pandas`, análisis estadístico descriptivo e inferencial (`numpy`, `scipy`, `statsmodels`) y una Red Neuronal Densa (`scikit-learn`, `Keras / TensorFlow`) dentro de un único **Dashboard Interactivo (`visuals/reporte_interactivo.html`)** con filtros dinámicos, tarjetas de KPIs, gráficos multivariados y un **Simulador de Pronóstico de Demanda**.

Público objetivo: (a) **Gerencia Comercial:** seguimiento de facturación en USD, ticket promedio, participación de exportaciones y elasticidad precio-demanda; (b) **Jefatura de Logística y Bodega:** control de alertas de reposición por SKU y planificación de embotellado estacional.

ii. Stack tecnológico

Capa	Librería / Tecnología	Versión	Función en el Proyecto
Lenguaje Base	Python	3.12.3	Orquestación modular, tipado y estructura general.
ETL y Datos	`pandas`	3.0.3	Carga de CSV, limpieza de nulos y duplicados, validación de rangos y `merge`.
Cálculo Numérico	`numpy`	2.4.6	Simulación reproducible (`seed=42`) y estadísticos descriptivos.
Tests Estadísticos	`scipy.stats`	1.18.1	Correlación lineal de Pearson (`pearsonr`) y test ANOVA de una vía (`f_oneway`).
Regresión Estadística	`statsmodels`	0.15.0	Regresión Lineal Múltiple OLS, inferencia de coeficientes (β), p-valores, AIC y BIC.
Machine Learning	`scikit-learn`	1.9.1	Partición 80/20 (`train_test_split`), escalado (`StandardScaler`) y métricas.
Deep Learning	`tensorflow / keras`	2.21.0 / 3.15.1	Red Neuronal Densa secuencial (`Dense 32 → 16 → 1`) para estimación no lineal.
Visualización	`matplotlib · seaborn · plotly`	3.10.9 · 0.13.2 · 6.8.0	Heatmap estático, barras mensuales por canal y dashboard interactivo HTML.

iii. Guía de instalación y ejecución (para programadores)

```
# 1. Clonar el repositorio público y entrar al directorio
git clone https://github.com/DarkosCode/WineLytics-V2.git
cd WineLytics-V2

# 2. Crear y activar entorno virtual (Linux/macOS o Windows PowerShell)
python3 -m venv .venv
source .venv/bin/activate          # En Windows: .venv\Scripts\Activate.ps1

# 3. Instalar dependencias fijadas
pip install -r requirements.txt

# 4. (Opcional) Regenerar los CSV sintéticos reproducibles (Semilla = 42)
python3 sources/generadorDeDatos.py

# 5. Ejecutar el pipeline completo (ETL + Estadística + Deep Learning + Dashboard HTML)
python3 main.py
```

c. Documentación técnica

i. Estructura de proyecto

```
WineLytics-V2/
├── data/                    # Datasets CSV generados (inventario.csv y ventas.csv)
├── schema/                  # Constantes centralizadas de columnas (inventario.py y ventas.py)
├── sources/                 # Generador sintético (generadorDeDatos.py) y cargadores ETL (inventario
├── backend/                 # Modelos analíticos: statsAnalysis.py (SciPy/Statsmodels) y deepLearnin
├── visuals/                 # Gráficos y reporte unificado: matplotUtils.py, seabornUtils.py, plotly
├── dataProcessing.py        # Orquestador del ETL, invocación del backend y consolidación (groupby +
├── main.py                  # Punto de entrada principal de la aplicación
├── requirements.txt         # Lista de paquetes con versiones exactas fijadas
└── README.md / CHANGELOG.md # Documentación técnica y registro cronológico de cambios
```

ii. Backend (diagrama pipeline de datos)

1. Capa de Origen y Esquemas (`sources/generadorDeDatos.py` + `schema/`): Genera con semilla `42` los archivos `data/inventario.csv` (12 SKUs) y `data/ventas.csv` (1.200 transacciones) aplicando constantes de nombres centralizadas.

▼

2. Capa de Extracción, Limpieza y Transformación (`sources/inventarioCsv.py` y `sources/ventasCsv.py`): Renombra columnas, imputa nulos (`fillna(0)`), elimina duplicados (`drop_duplicates`), valida rangos positivos y calcula `Reposicion Necesaria` , `Ingreso Total` , `Mes` (en español) y `Estacion` .

▼

3. Capa Analítica y Predictiva (`backend/statsAnalysis.py` + `backend/deepLearning.py`): • **Estadística:** Calcula resumen descriptivo (`numpy`), correlación de Pearson y ANOVA (`scipy.stats`) y ajusta Regresión OLS (`statsmodels`), inyectando la columna `Prediccion_Ventas` .
• **Deep Learning:** Codifica dummies (One-Hot), divide 80/20 (`random_state=42`), estandariza con `StandardScaler` en train y entrena la red `Dense(32, relu)` → `Dense(16, relu)` → `Dense(1)` , inyectando la columna `Prediccion_DL` .

▼

> **4. Capa de Consolidación y Visualización (`dataProcessing.py` → `visuals/` → `main.py`):** Agrupa ventas por `[Varietal, Linea]` , realiza `inner merge` con inventario, exporta los PNG de Matplotlib/Seaborn y ensambla `visuals/reporte_interactivo.html` con filtros, 6 KPIs, gráficos Plotly y Simulador.

iii. Modelo analítico (explicación y comparativa)

- **Estadística Descriptiva y Tests (SciPy):** Media de **195.96 botellas/venta** (mediana 195.0, desvío 63.13) y precio medio de **$20.56 USD**. La correlación de Pearson entre Precio y Unidades es **r = -0.7324 (p = 3.06e-202)** confirmando la ley de demanda inversa. El test ANOVA entre estaciones arroja **F = 43.52 (p = 1.08e-26)**, confirmando diferencias estacionales altamente significativas.
- **Regresión Lineal Múltiple OLS (Statsmodels):** Modela `Unidades ~ const + Precio + dummies(Canal, Varietal, Estacion)` . Se excluye `Linea` por colinealidad directa con el precio (reduciendo el número de condición de 546 a 117). Cada dólar extra de precio reduce las ventas en **-3.91 botellas**.
- **Red Neuronal Densa (Keras / TensorFlow):** Arquitectura secuencial `Input(8) → Dense(32, ReLU) → Dense(16, ReLU) → Dense(1, Lineal)` entrenada 50 épocas con `Adam(lr=0.01)` y pérdida `MSE` .

Métrica en Conjunto de Prueba (Test 20% = 240 ventas, Semilla 42)	Regresión OLS (Statsmodels)	Red Neuronal Densa (Keras / TF)	Ventaja de Deep Learning
Coeficiente de Determinación (R^2 Test)	0.6739 (67.4%)	**0.8734 (87.3%)**	**+19.95 puntos de R^2**
Error Absoluto Medio (MAE Test)	27.62 botellas	**17.27 botellas**	**-37.5% de error promedio**
Raíz del Error Cuadrático Medio (RMSE Test)	34.97 botellas	**21.79 botellas**	**-37.7% en errores grandes**

Conclusión analítica: Mientras que el OLS suma efectos individuales por separado, las capas ocultas con función de activación no lineal `ReLU` de la Red Neuronal capturan automáticamente la interacción **Varietal × Estación** (el salto de *Torrontés* en verano y de *Malbec/Cabernet* en invierno).

iv. Guía de estilo (tema, paleta de colores y tipografía)

Se definió la identidad visual unificada **"Bodega / Vino"** con tipografía `Arial, Helvetica, sans-serif` en todos los módulos:

Muestra	Nombre Semántico	HEX	Aplicación en el Sistema
☐	**Bordó Reserva**	`#722F37`	Encabezados, serie de ventas reales, canal Mercado Interno y bordes principales.
☐	**Carmín Intenso**	`#A4133C`	Botones interactivos en estado hover y acentos secundarios.
☐	**Dorado Crianza**	`#C59B27`	Canal Exportación, serie Deep Learning, curva de validación y Simulador.
☐	**Rojo Alerta**	`#C0392B`	SKUs que requieren reposición inmediata (`Stock < Punto de Reposición`).
☐	**Verde Stock OK**	`#27AE60`	SKUs con disponibilidad saludable en depósito.
☐	**Crema Pergamino**	`#FAF7F5`	Fondo general del dashboard y lienzos de Matplotlib y Seaborn.

v. Capturas de pantalla y señalización de componentes del Dashboard

El archivo `visuals/reporte_interactivo.html` presenta la siguiente distribución señalizada de componentes:

1. **Barra Superior de Filtros Interactivos:** Desplegables de *Varietal*, *Estación* y *Canal de Venta* + botón *Restablecer Filtros*.
2. **Grilla de 6 Tarjetas de KPIs:** *Ingreso Total ($4,167,220 USD) · Unidades Vendidas (235,157 u.) · Ticket Promedio ($3,472.68) · Share Exportación (51.0%) · Alerta de Stock (SKUs) · Precisión R² Test (DL 87.3% vs OLS 67.4%)*.
3. **Sección 1 — Visualización Comercial e Inventario:** Gráfico interactivo Plotly de burbujas (con filtro de reposición) + Heatmap Matplotlib y Barras Seaborn.
4. **Sección 2 — Estadística Descriptiva y Regresión OLS:** Tabla de media/mediana/desvío, resultados de Pearson y ANOVA y tabla de coeficientes β.
5. **Sección 3 — Aprendizaje Profundo:** Gráfico interactivo Plotly *Real vs. OLS vs. Red Neuronal* (filtrable por varietal) y *Curva de Aprendizaje (Loss MSE)*.
6. **Simulador Interactivo de Demanda:** Selectores de *Varietal, Estación, Línea y Canal* que comparan en vivo la demanda histórica frente al pronóstico OLS y de la Red Neuronal.

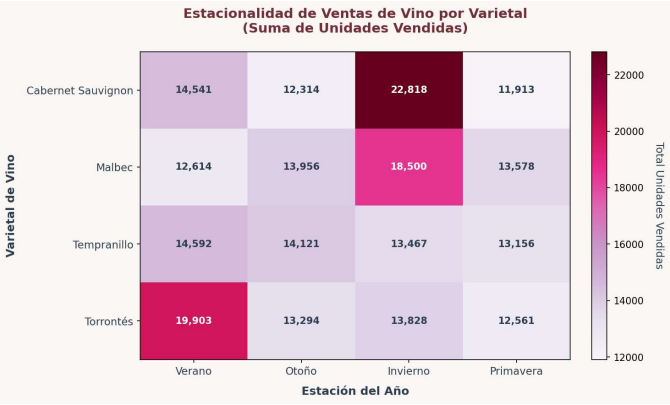


Figura 1 (Matplotlib): Mapa de calor de unidades vendidas por varietal y estación.

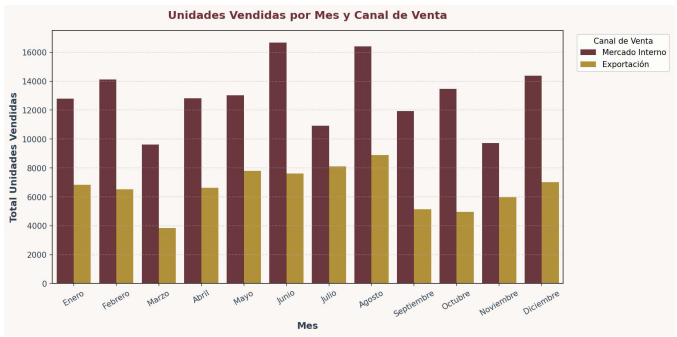


Figura 2 (Seaborn): Ventas mensuales en español según canal comercial.

vi. Enlace a repositorio público de GitHub

Código fuente completo disponible en: **https://github.com/DarkosCode/WineLytics-V2**

d. Gobierno de datos

i. Fuentes de datos

Los datasets se originan mediante el simulador paramétrico `sources/generadorDeDatos.py` con semilla fija (`SEMILLA = 42`), produciendo `data/inventario.csv` (12 SKUs únicos: 4 varietales × 3 líneas) y `data/ventas.csv` (1.200 transacciones del año 2025).

ii. Tuberías de limpieza y transformación (pandas)

1. **Normalización de esquema (`rename`):** Mapeo desde los encabezados crudos `CSV_*` hacia las constantes canónicas `COL_*` definidas en `schema/` .
2. **Tratamiento de nulos y tipado (`fillna(0)` + `astype`):** Conversión explícita a tipos numéricos (`int` para unidades y stock; `float` para precios).
3. **Deduplicación y validación de dominio (`drop_duplicates`):** Eliminación de filas repetidas y validación lógica (`Unidades > 0` , `Precio > 0` , `Stock >= 0`).
4. **Ingeniería de atributos:** Cálculo vectorial de `Reposicion Necesaria` (`"SI"/"NO"`), `Ingreso Total` , `Mes` en español y `Estacion` , más las columnas predictivas `Prediccion_Ventas` y `Prediccion_DL` .
5. **Consolidación relacional (`groupby` + `pd.merge`):** Resumen de ventas por `[Varietal, Linea]` unido mediante `inner join` con el inventario físico.

iii. Diccionario de datos

Dataset / Origen	Columna Canónica	Tipo	Valores / Unidad	Descripción
`inventario.csv`	`Varietal`	string	Malbec, Cabernet S., Tempranillo, Torrontés	Varietal de uva (clave primaria compuesta del SKU).
`inventario.csv`	`Linea`	string	Joven, Reserva, Gran Reserva	Categoría de crianza del vino.
`inventario.csv`	`Stock Actual`	int64	Botellas (≥ 0)	Existencia física disponible en depósito.
`inventario.csv`	`Punto de reposición`	int64	2.500 / 3.500 / 5.000 botellas	Umbral crítico que dispara orden de reposición.
Derivada (ETL)	`Reposicion Necesaria`	string	"SI" / "NO"	Bandera de alerta cuando Stock Actual < Punto de reposición.
`ventas.csv`	`Fecha`	datetime64	YYYY-MM-DD (Año 2025)	Fecha de registración de la operación comercial.
`ventas.csv`	`Canal de Venta`	string	Mercado Interno / Exportación	Canal de distribución de la venta.
`ventas.csv`	`Unidades Vendidas`	int64	48 a 393 botellas	Cantidad vendida en la transacción (variable objetivo *y*).
`ventas.csv`	`Precio Unitario`	float64	$7.60 a $47.22 USD	Precio unitario por botella en dólares equivalentes.
Derivada (ETL)	`Ingreso Total`	float64	USD (Unidades × Precio)	Facturación bruta de la transacción.
Derivada (ETL)	`Mes / Estacion`	string	Enero–Diciembre / 4 estaciones	Atributos temporales derivados de la fecha (hemisferio sur).
Backend Analítico	`Prediccion_Ventas / Prediccion_DL`	float64	Botellas estimadas	Pronóstico de demanda por transacción según OLS y Red Neuronal.

e. Guía de usuario

i. Glosario de métricas y KPIs

Indicador / Métrica	Fórmula / Cálculo	Utilidad para la Toma de Decisiones
Ingreso Total	`Σ(Unidades × Precio Unitario)`	Mide la facturación bruta acumulada en USD según los filtros activos.
Unidades Vendidas	`Σ Unidades Vendidas`	Volumen total de botellas despachadas e intensidad media por pedido.
Ticket Promedio	`Ingreso Total / N° Transacciones`	Valor monetario promedio de cada transacción comercial.
Share Exportación	`(Ingreso Exportación / Ingreso Total) × 100`	Peso porcentual de las ventas externas sobre la facturación total.
Alerta de Stock (SKUs)	`Conteo(Stock < Punto de Reposición)`	Identifica cuántos de los 12 productos del catálogo están en riesgo de quiebre.
R² / MAE / RMSE (Test)	Métricas sobre el 20% de prueba	Evalúan la calidad predictiva: la Red Neuronal logra R² = 87.3% y MAE = 17.27 botellas.

ii. Guía de navegación e interactividad

1. **Barra de Filtros Globales (Zona 1):** Seleccione un *Varietal*, *Estación* o *Canal* en los desplegables superiores para recalcular al instante las tarjetas de KPIs. Use el botón **Restablecer Filtros** para volver al total anual.
2. **Controles en Gráficos Interactivos (Plotly):** En el gráfico de burbujas utilice los botones superiores (*Todos los SKUs*, *Solo Alerta Reposición*, *Solo Stock OK*) para aislar productos críticos. En el gráfico comparativo de modelos utilice el selector desplegable de varietal para inspeccionar el ajuste estacional.
3. **Simulador de Pronóstico de Demanda (Zona 6):** Elija la combinación deseada de *Varietal* + *Estación* + *Línea* + *Canal* en la parte inferior del dashboard para comparar la demanda histórica frente al pronóstico del modelo OLS y de la Red Neuronal.

iii. FAQ (Preguntas Frecuentes)

1. ¿Necesito ejecutar un servidor web para usar el dashboard?
No. El archivo `visuals/reporte_interactivo.html` es 100% autónomo: incluye los datos precalculados y las imágenes codificadas en Base64, por lo que se abre con doble clic en cualquier navegador.

2. ¿Por qué el pronóstico de Deep Learning es más preciso que el de la Regresión OLS?
Porque la demanda vitivinícola tiene interacciones estacionales fuertes (*Torrontés* sube en verano y los tintos en invierno). El OLS aditivo promedia esos efectos, mientras que la Red Neuronal los detecta mediante sus capas ocultas con activación `ReLU`.

3. ¿Por qué no se incluye la variable "Línea" dentro de los predictores de la regresión?
Porque el `Precio Unitario` está definido por la línea del vino. Incluir ambas genera multicolinealidad redundante; el precio ya captura ese efecto con mayor precisión numérica.

4. ¿Cómo actualizo el dashboard si se agregan nuevas ventas al CSV?
Simplemente ejecute `python3 main.py`. El sistema volverá a correr la limpieza, reentrenará ambos modelos y actualizará `visuals/reporte_interactivo.html`.